

Universidad de Ingenieria y Tecnologia
Departamento de Ciencias de la Computación

Arquitectura de Software

Caso de Estudio #5
2026 - II

TEAM	
INTEGRANTES	
Puntos	20 ptos (Reliability)

Background:

Reliability Patterns

Fault Tolerance

Caso de Estudio: Genius-x (new !! - piece of cake)

Genius es el software que usa una compañía para manejar los incidentes diarios que se tienen en la empresa. Los tipos de incidentes pueden ser los siguientes:


INCIDENTE	DESCRIPCIÓN
Customer Escalations	Escalamientos o reportes de incidente que vienen del cliente mismo. Estos tienen impacto en negocio directo
Engineering Escalations	Estos son incidentes reportados por el área de ingeniería para sí mismos o otras áreas.
Support Escalations	Escalamientos que fueron reportados por clientes pero fueron procesados previamente por el area de soporte.

Dado que el detalle de incidentes es elevado y no puede ser público. El área de data science ha elegido un LLM en local y se le dio una API al área de manejo de incidentes para poder que el LLM pueda dar información así como tomar acciones: queries a base datos, E2E testing, etc.

El último mes hubo un problema en el que un ingeniero de soporte dio instrucciones para una escalamiento de un cliente en la cual el LLM decidió borrar la base de datos. También hay múltiples quejas de que el LLM no está aprendiendo y siempre da respuestas erróneas o de data pasada.

Su trabajo **es diseñar un nuevo harness para el LLM** ya que el actual solo conectaba con MCP a base de datos, slack y API LLM.

El día con más incidentes es la primera semana de cada mes donde tenemos que el LLM tiende a no responder o responde en forma errada. Otras veces responde en forma diferente para las mismas preguntas. Y tenemos un conjunto de preguntas comunes que cada día el LLM responde en forma diferente. Al mismo tiempo, soporte se queja de que Genius a veces responde con el estado de un incidente que ya fue cerrado hace horas.



Requerimientos NO Funcionales:

- Hablamos de 10,000 incidentes por semana. O más dependiendo de los picos.
- Se tienen un número de 50 a 100 ingenieros accediendo a la plataforma.
- El SLA de respuesta de customer escalations es de 1 día. Engineering escalations de 3 días.
- Disponibilidad y **tolerancia a fallos**.
- Tiempo real (**latencia mínima para decisiones críticas**).

Entregables

- Diagrama de Arquitectura con reliability y fault tolerance.

Hints/Tips:

- Identifique los SPOF.
- Identifique componentes de riesgo alto

Harness:

- Son todos los componentes alrededor del LLM que hacen que este tenga la mejor performance/confiabilidad y experiencia de uso.